

LGA 各个指标的计算公式

对，这里建议你记录 **4** 类指标：

主指标 = **LGA** 内积分数；

辅助诊断 = **cosine**、**gradient norm**、**norm-dominance ratio**。

下面给你完整公式。

1. 基础符号定义

对第 i 个样本：

$$x_i = (I_i, Q_i)$$

其中：

$$I_i = \text{image}, \quad Q_i = \text{request prompt}$$

旧答案：

$$y_i^{old}$$

新目标答案：

$$y_i^{new}$$

第 L 层参数：

$$\theta_L$$

old loss：

$$\mathcal{L}_{old}^i = CE(M(x_i), y_i^{old})$$

new loss：

$$\mathcal{L}_{new}^i = CE(M(x_i), y_i^{new})$$

第 L 层 old 梯度：

$$g_{old}^{i,L} = \nabla_{\theta_L} \mathcal{L}_{old}^i$$

第 L 层 new 梯度：

$$g_{new}^{i,L} = \nabla_{\theta_L} \mathcal{L}_{new}^i$$

原文 LGA 就是基于这种**层级梯度内积**来估计 golden layer: 对 proxy set 中 old knowledge 和 new target knowledge 的层梯度内积求和, 然后取最高层。

2. 主指标: LGA Dot Product Score

这是你的主实验指标。

单个样本、单层:

$$s_{\text{dot}}^{i,L} = (g_{old}^{i,L})^\top g_{new}^{i,L}$$

展开理解就是:

$$s_{\text{dot}}^{i,L} = \sum_{j=1}^{d_L} g_{old,j}^{i,L} g_{new,j}^{i,L}$$

其中 d_L 是第 L 层参数量。

proxy set 聚合:

$$S_{\text{dot}}(L) = \sum_{i=1}^N (g_{old}^{i,L})^\top g_{new}^{i,L}$$

最终 golden layer:

$$G^* = \arg \max_L S_{\text{dot}}(L)$$

你的 LLaVA / BLIP2 分别计算:

$$G_{\text{LLaVA}}^* = \arg \max_L S_{\text{dot}}^{\text{LLaVA}}(L)$$

$$G_{\text{BLIP2}}^* = \arg \max_L S_{\text{dot}}^{\text{BLIP2}}(L)$$

解释:

$$g_{old} \cdot g_{new} = \|g_{old}\| \|g_{new}\| \cos(\theta)$$

所以 dot product 同时包含:

1. 梯度方向是否一致
2. 这一层梯度响应强不强

因此它更接近原文想衡量的“该层对 old -> new 知识替换的影响力”。

3. 辅助指标一：Cosine Similarity Score

这是诊断指标，不作为主选层依据。

单个样本、单层：

$$s_{\cos}^{i,L} = \frac{(g_{old}^{i,L})^\top g_{new}^{i,L}}{\|g_{old}^{i,L}\|_2 \|g_{new}^{i,L}\|_2 + \epsilon}$$

其中 ϵ 是防止除零的小数，例如：

$$\epsilon = 10^{-8}$$

proxy set 聚合可以用平均：

$$S_{\cos}(L) = \frac{1}{N} \sum_{i=1}^N s_{\cos}^{i,L}$$

也可以用加权平均，但建议第一版用普通平均。

解释：

- $S_{\cos}(L)$ 高：old 和 new 的梯度方向相似；
 - $S_{\cos}(L)$ 低或负：old 和 new 的更新方向不一致；
 - 如果 dot 很高但 cosine 不高，说明这一层可能是被梯度范数放大，而不是真正方向对齐。
-

4. 辅助指标二：Gradient Norm

这个用来判断某层是不是出现异常大梯度。

old gradient norm：

$$n_{old}^{i,L} = \|g_{old}^{i,L}\|_2$$

new gradient norm：

$$n_{new}^{i,L} = \|g_{new}^{i,L}\|_2$$

合并 norm:

$$n_{\text{joint}}^{i,L} = \|g_{old}^{i,L}\|_2 \|g_{new}^{i,L}\|_2$$

proxy set 平均:

$$N_{old}(L) = \frac{1}{N} \sum_{i=1}^N \|g_{old}^{i,L}\|_2$$

$$N_{new}(L) = \frac{1}{N} \sum_{i=1}^N \|g_{new}^{i,L}\|_2$$

$$N_{\text{joint}}(L) = \frac{1}{N} \sum_{i=1}^N \|g_{old}^{i,L}\|_2 \|g_{new}^{i,L}\|_2$$

解释:

- norm 高: 该层对 loss 变化敏感;
- norm 极端高: 可能是异常梯度;
- dot 高 + norm 高 + cosine 低: 需要警惕;
- dot 高 + norm 中等 + cosine 高: 比较可信。

5. 辅助指标三: Norm-Dominance Ratio

这个指标用来判断:

LGA dot 分数高, 到底是因为方向真的对齐, 还是因为梯度范数太大?

因为:

$$s_{\text{dot}}^{i,L} = \|g_{old}^{i,L}\|_2 \|g_{new}^{i,L}\|_2 s_{\text{cos}}^{i,L}$$

所以可以定义:

$$R_{\text{norm-dom}}(L) = \frac{S_{\text{dot}}(L)}{N_{\text{joint}}(L) + \epsilon}$$

但注意, 严格来说这个值近似反映方向因素, 和 cosine 有关系。

更直观的诊断可以这样写:

$$D(L) = \frac{N_{\text{joint}}(L)}{\frac{1}{|\mathcal{L}|} \sum_{k \in \mathcal{L}} N_{\text{joint}}(k) + \epsilon}$$

其中 $|\mathcal{L}|$ 是候选层数量。

解释：

- $D(L) \approx 1$ ：该层梯度范数正常；
- $D(L) \gg 1$ ：该层梯度范数远高于平均，可能主导 dot；
- $D(L) \ll 1$ ：该层梯度响应很弱。

如果某一层：

$$S_{\text{dot}}(L) \text{ rank} = 1$$

但：

$$S_{\text{cos}}(L) \text{ 很低, } D(L) \gg 1$$

那说明这个层可能不是理想 golden layer，而是“梯度范数异常大”。

6. 辅助指标四：Rank Consistency

这个不是原文指标，但很适合你分析 LLaVA / BLIP2。

分别计算三个排名：

$$r_{\text{dot}}(L)$$

$$r_{\text{cos}}(L)$$

$$r_{\text{norm}}(L)$$

其中 rank 越小表示越靠前。

可以定义一致性：

$$C_{\text{rank}}(L) = \frac{r_{\text{dot}}(L) + r_{\text{cos}}(L)}{2}$$

或者更简单地报告：

Dot Rank

Cosine Rank

Norm Rank

Adapter Rank

你真正希望看到的是：

Dot Rank 高
 Cosine Rank 也较高
 Norm Rank 不异常
 Adapter Rank 也高
 这说明 LGA 选层可靠。

7. 你最终表格可以这样设计

Model	Layer	Dot Score (higher)	Dot Rank	Cosine (higher)	Cos Rank	Joint Norm	Norm Ratio	LGA Se- lected
LLaVA	0							
LLaVA	1							Yes
LLaVA	2							
BLIP2	15							
BLIP2	19							Yes

8. 你的主实验最终采用哪个公式?

主实验只用这个:

$$S_{\text{LGA}}(L) = S_{\text{dot}}(L) = \sum_{i=1}^N (g_{old}^{i,L})^\top g_{new}^{i,L}$$

golden layer:

$$G^* = \arg \max_L S_{\text{LGA}}(L)$$

辅助分析报告:

$$S_{\text{cos}}(L)$$

$$N_{\text{joint}}(L)$$

$$D(L)$$

一句话总结:

Dot product 是主指标; **cosine**、**gradient norm**、**norm ratio** 是诊断指标, 用来解释 **dot product** 选出的层是否可靠。