


图 3 MiniGPT4 × E-VQA • 首预测位置对照：高贡献与编辑收益不一致

main 配方 | 归因样本 N=500 | 编辑评测 N=2093 | 层号从 0 开始



参照层优势 (百分点)
读图: A 排贡献越高, 柱越高; B 排为实际得分; C 排为低贡献参照层减去高贡献层, 正值表示低贡献层编辑更好。
首预测位置是原始图文输入末位的 next-token argmax, 不是完整旧答案归因。L26/L30 的 EMA loss 为 0.374/0.481。
仅展示已有实测反例, 非总体胜率或显著性检验; T-Loc/M-Loc 详见正文。冻结台账: 2026-09-28; PaliGemma 已排除。